Tema 3 - Analiza de clusteri
–
Analiza de clusteri pentru clasificarea tarilor din Uniunea Europeana dupa nivelul de dezvoltare

Scopul proiectului

Scopul proiectului este sa grupeze tarile din Uniunea Europeana in functie de nivelul de dezvoltare, folosind o analiza de clusteri. Ideea principala este sa vedem ce tari sunt similare intre ele, pe baza unor indicatori socio-economici, si sa obtinem grupuri usor de interpretat (de exemplu: dezvoltare ridicata, medie, mai scazuta).

Datele folosite

Datele provin din World Bank si au fost preluate din fisiere CSV separate, cate unul pentru fiecare indicator. Am ales 5 indicatori care au sens pentru compararea nivelului de dezvoltare:

- PIB pe cap de locuitor (indicator economic) - data_in /pib_pe_cap_de_locuitor_nefiltrat.csv
- Speranta de viata (indicator social) - data_in/ speeranta_de_viata_nefiltrat.csv
- Populatie urbana (%) - data_in/populatie_urbana_nefiltrat.csv
- Utilizatori de internet (%) - data_in/utilizatori_internet_nefiltrat.csv
- Cheltuieli pentru educatie (% din PIB) data_in/heltuieli_educatie_nefiltrat.csv

Am lucrat cu tarile UE-27 (fara UK).

Construirea setului de date final (un singur an comun)

Pentru ca analizele sa fie corecte, tarile trebuie comparate in **acelasi an**. In practica, unele tari au date lipsa la anumiti indicatori in anii cei mai noi (mai ales educatia), asa ca am procedat astfel:

1. Am citit fiecare fisier (indicator) in format World Bank.
2. Am filtrat doar tarile UE.
3. Am cautat un **an comun bun**: adica cel mai recent an care ofera acoperire cat mai mare (cat mai multe tari cu valori prezente la toti indicatorii).
4. Am construit tabelul final: un rand = o tara, o coloana = un indicator.
5. Am exportat datasetul final: `dataset_cluster_UE.csv`.

Rezultatul final este un tabel cu tarile UE si cei 5 indicatori, pentru acelasi an comun ales automat.

Preprocesarea datelor

Tratarea valorilor lipsa (NaN)

Daca o tara nu are o valoare la un indicator, apar `NaN`. Pentru a putea rula clusterizarea fara erori, am completat valorile lipsa cu **media coloanei** (media indicatorului pentru tarile care au date).

Motiv: nu vrem sa eliminam prea multe tari doar din cauza unor valori lipsa.

Standardizare z-score

Indicatorii au scari diferite (PIB e mult mai mare ca procentele), deci fara standardizare PIB-ul ar domina distanta si ar influenta prea mult clusterele.

De aceea am standardizat cu z-score:

- fiecare coloana devine comparabila (media 0, deviatie standard 1)
- toate variabilele contribuie “aproximativ egal” la distanta

Metoda de clusterizare folosita

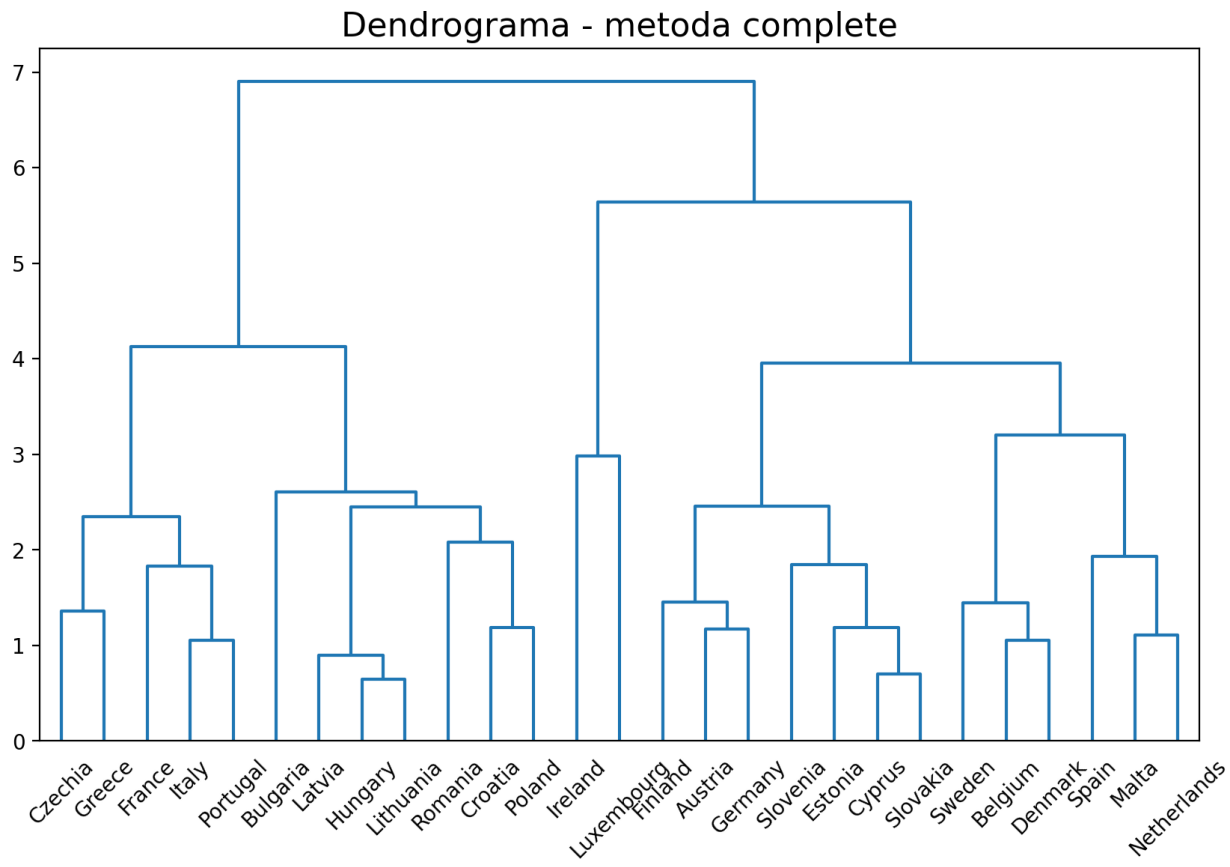
Am folosit clusterizare ierarhica, cu metoda de legare **complete**. Output-ul principal al acestei metode este matricea de ierarhie si dendrograma.

Pe scurt:

- fiecare tara incepe ca un cluster separat
- apoi se unesc pas cu pas cele mai apropiate clustere
- procesul continua pana ajungem la un singur cluster mare

Dendrograma (structura ierarhica)

Aici se vede cum sunt unite tarile si la ce distante.



Explicatie:

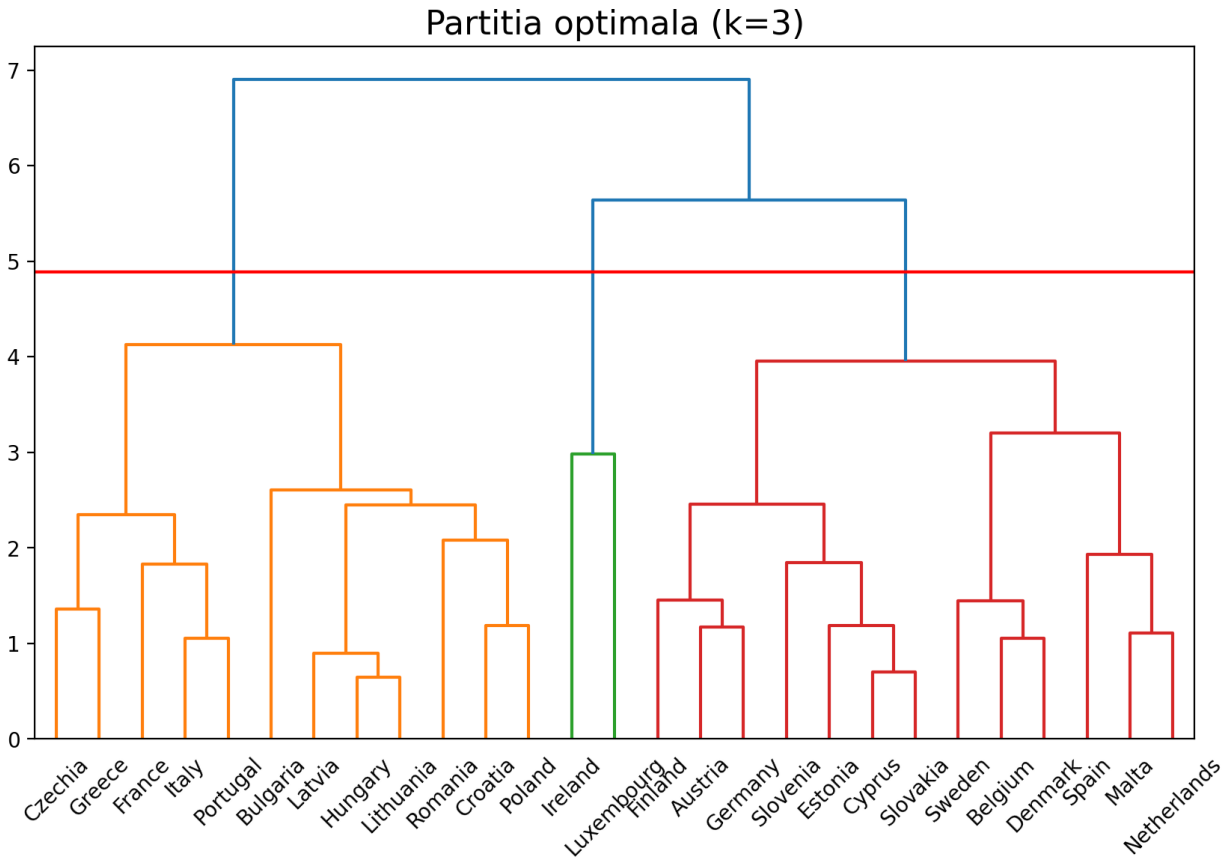
Pe axa X sunt tarile, iar pe axa Y este distanta la care se fac unirile. Ramuri care se unesc mai jos inseamna tari mai similare; unirile sus inseamna diferente mai mari.

Determinarea partitiei optime (Elbow)

Pentru a alege cate clustere sa avem, am folosit o idee de tip “Elbow”: ne uitam unde exista cea mai mare crestere intre distantele de unire consecutive. Acel punct sugereaza un prag bun pentru “taierea” dendrogramei.

Scriptul a calculat:

- `k_opt` = numarul de clustere pentru partitia optima
- `prag_opt` = distanta de taiere pe dendrograma
- `p_opt` = etichetele clusterelor pentru fiecare tara (C1, C2, …)



Explicatie:
Linia rosie arata pragul la care taiem. Sub acea linie se formeaza clusterele. Culorile diferite indica grupurile obtinute.

Evaluarea clusterelor cu Silhouette

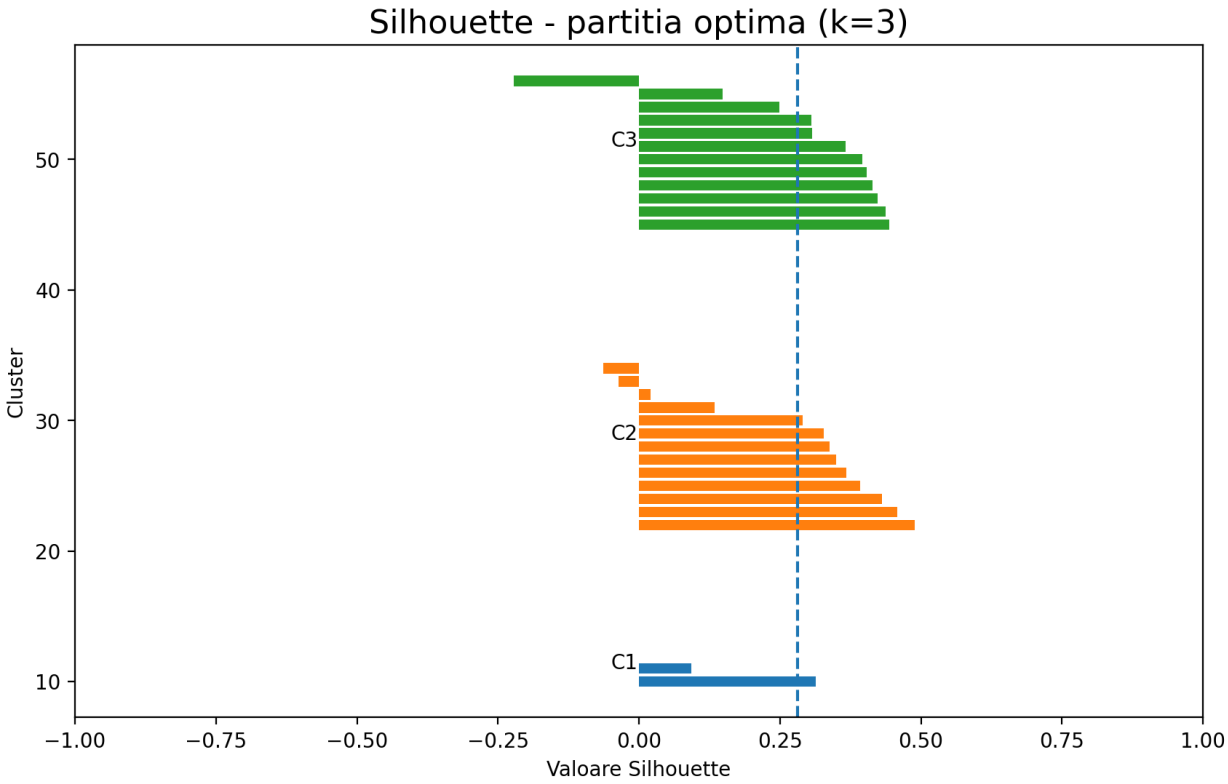
Pentru a verifica daca separarea in clustere este buna, am calculat scorul Silhouette.

Pe scurt:

- valoare aproape de 1 = tara e bine incadrata in clusterul ei
- aproape de 0 = tara este “la limita” intre clustere
- negativ = posibil plasata prost (mai apropiata de alt cluster)

Am calculat:

- scor Silhouette pentru partitia optima
- scor Silhouette si pentru o partitie alternativa cu k fix (k=3), ca sa comparam



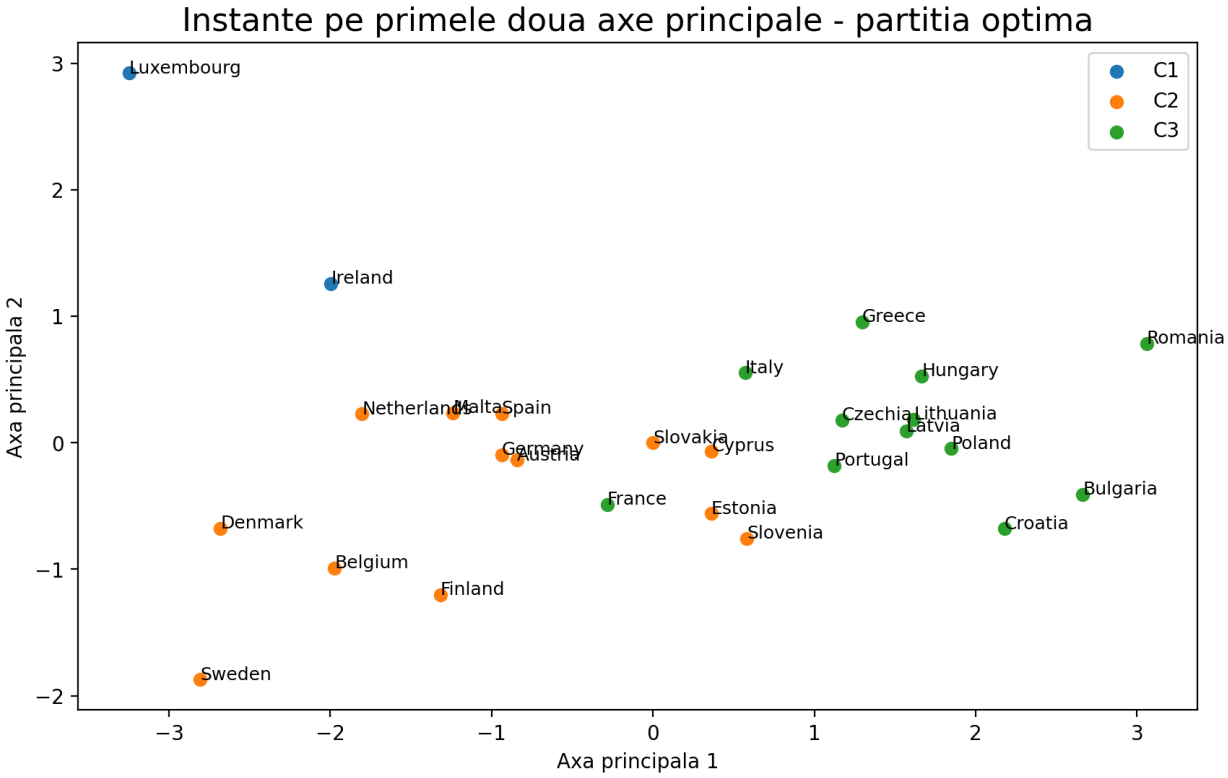
Explicatie:
Barele sunt valorile silhouette pentru fiecare tara, grupate pe clustere. Linia punctata este media (scorul global). Daca majoritatea barelor sunt pozitive, partitia este acceptabila.

Reprezentare 2D pe primele doua axe principale

Ca sa vizualizam mai usor tarile (in 2D), am proiectat datele pe primele doua axe principale (o varianta de PCA simplificat). Aceste axe comprima informatia din cei 5 indicatori in doua coordonate, ca sa putem vedea separat clusterele pe un scatter plot.

Am calculat:

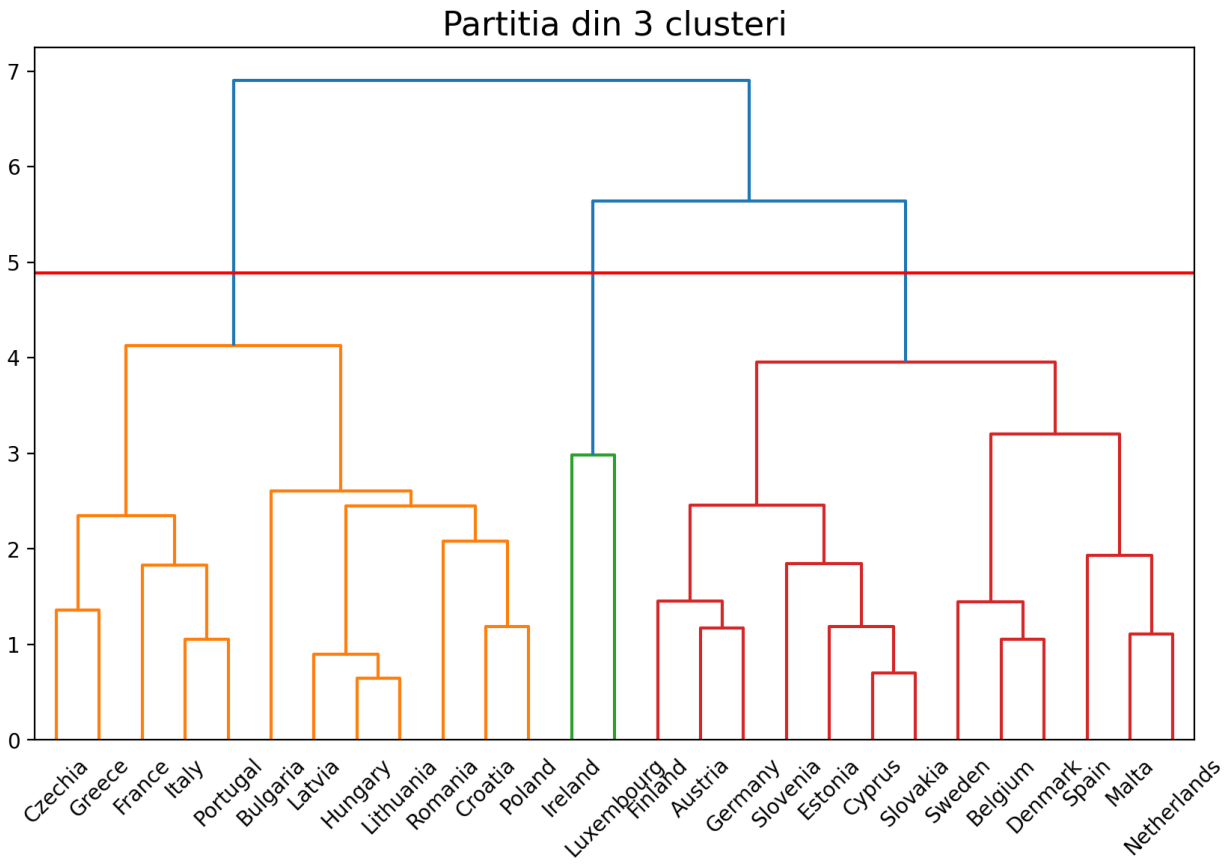
- procentul de varianta explicata de Axa1 si Axa2
- coordonatele tarilor in planul (Axa1, Axa2)



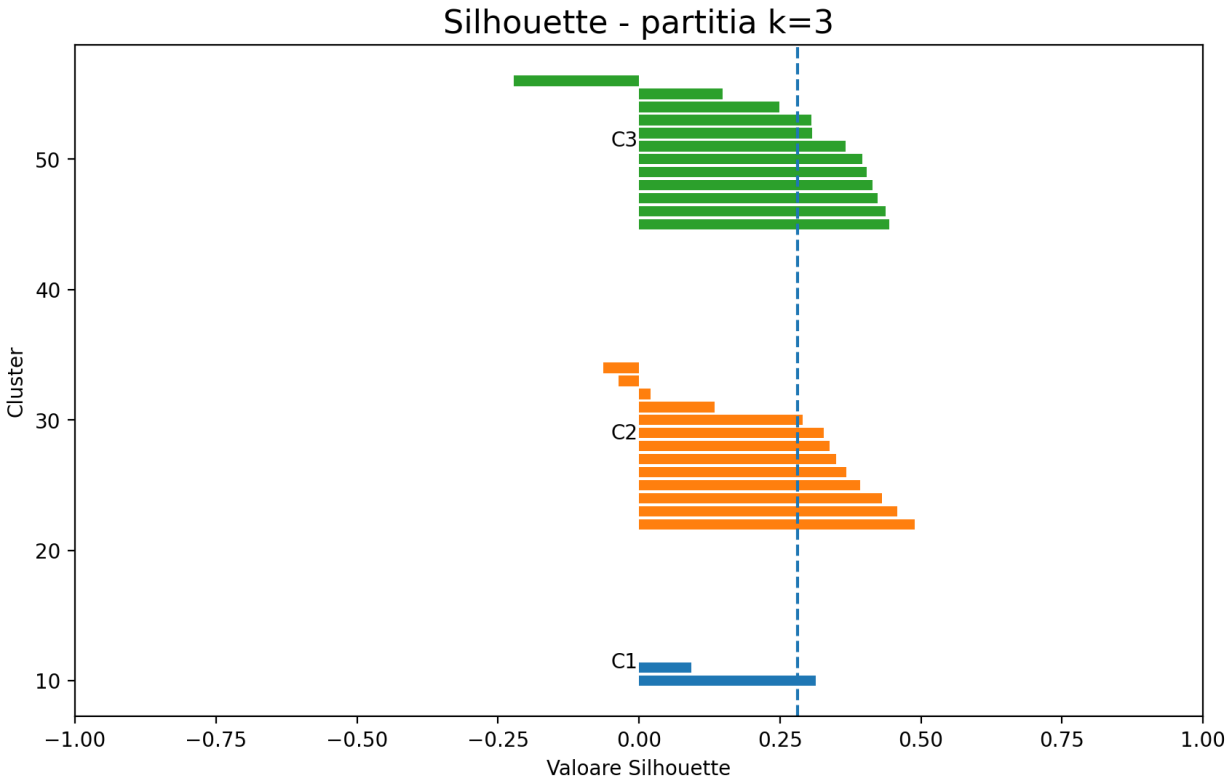
Explicatie:
Punctele sunt tarile, culorile sunt clusterele. Daca grupurile sunt “adunate” si separate, inseamna ca partitia are sens si vizual.

A doua partitie (k fix = 3) + Silhouette

Pe langa partitia optima, am generat o partitie cu numar fix de clustere (k=3) pentru comparatie.



Explicatie:
Aceeasi dendrograma, dar taiata astfel incat sa obtinem exact 3 clustere.

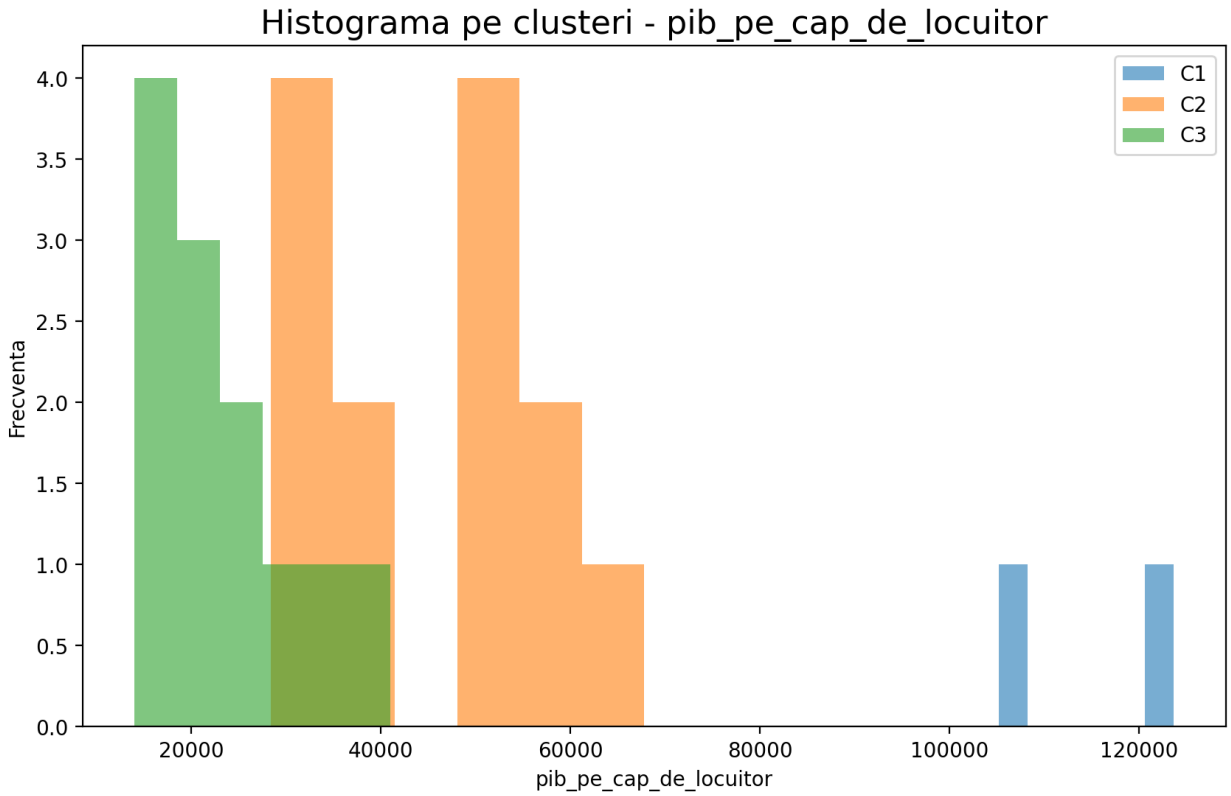


Explicatie:

Comparand scorul silhouette cu partitia optima, vedem daca 3 clustere sunt o alegere la fel de buna sau mai slaba.

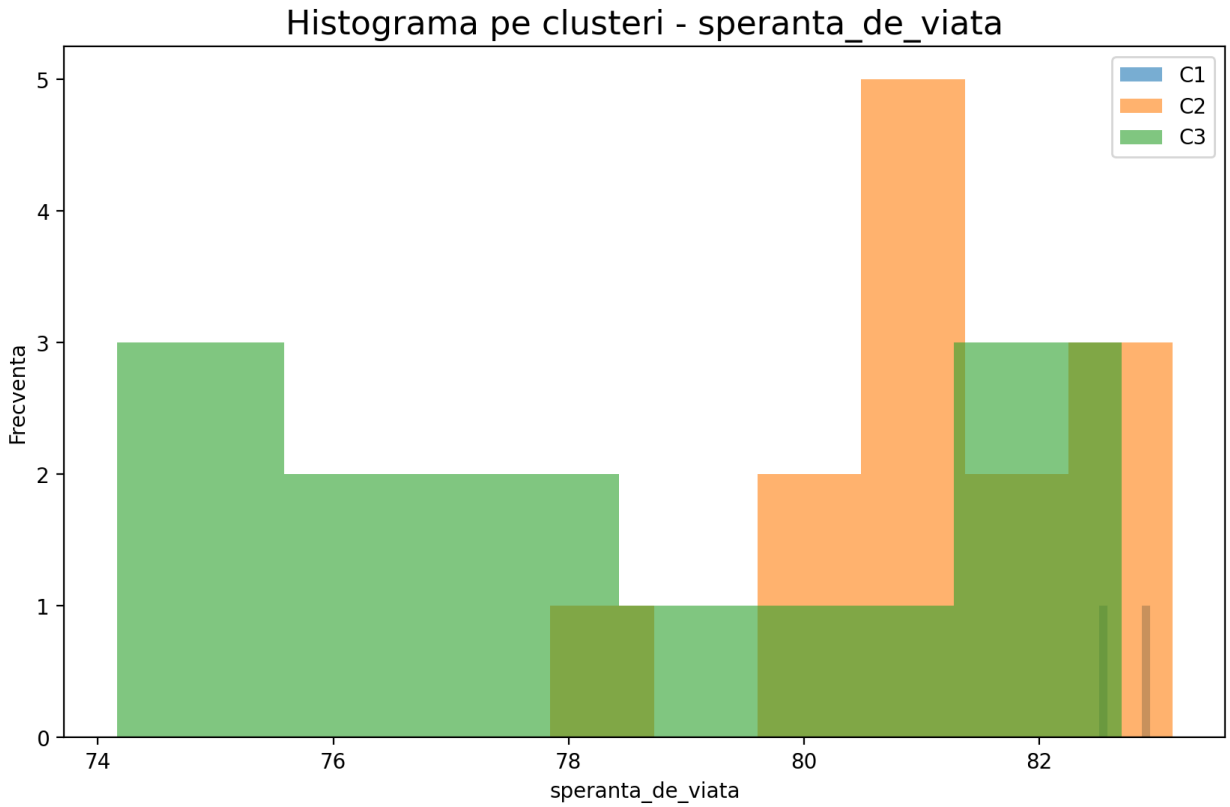
Histograme pe clustere (compararea indicatorilor)

Pentru interpretare, am construit histograme pe clustere pentru fiecare indicator. Asta arata cum se distribuie valorile in fiecare grup.



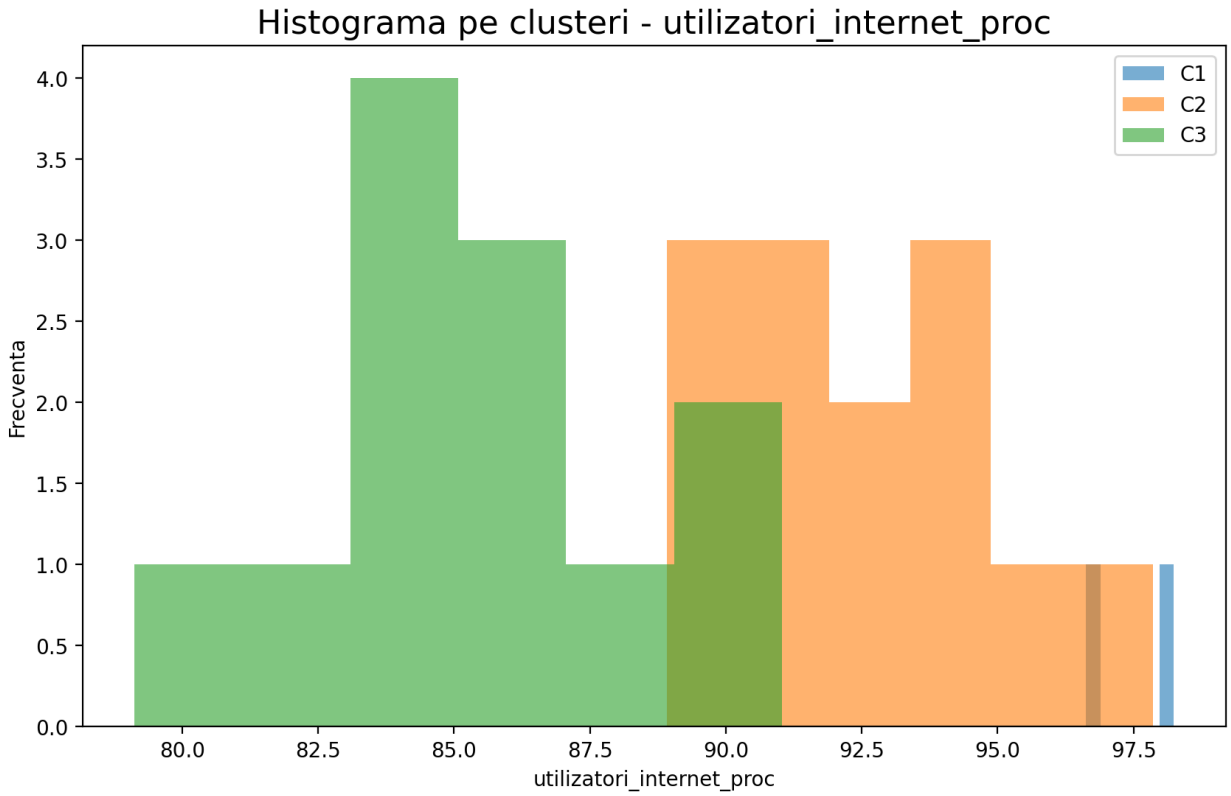
Explicatie:

Se observa daca exista un cluster cu PIB clar mai mare si unul cu PIB mai mic.



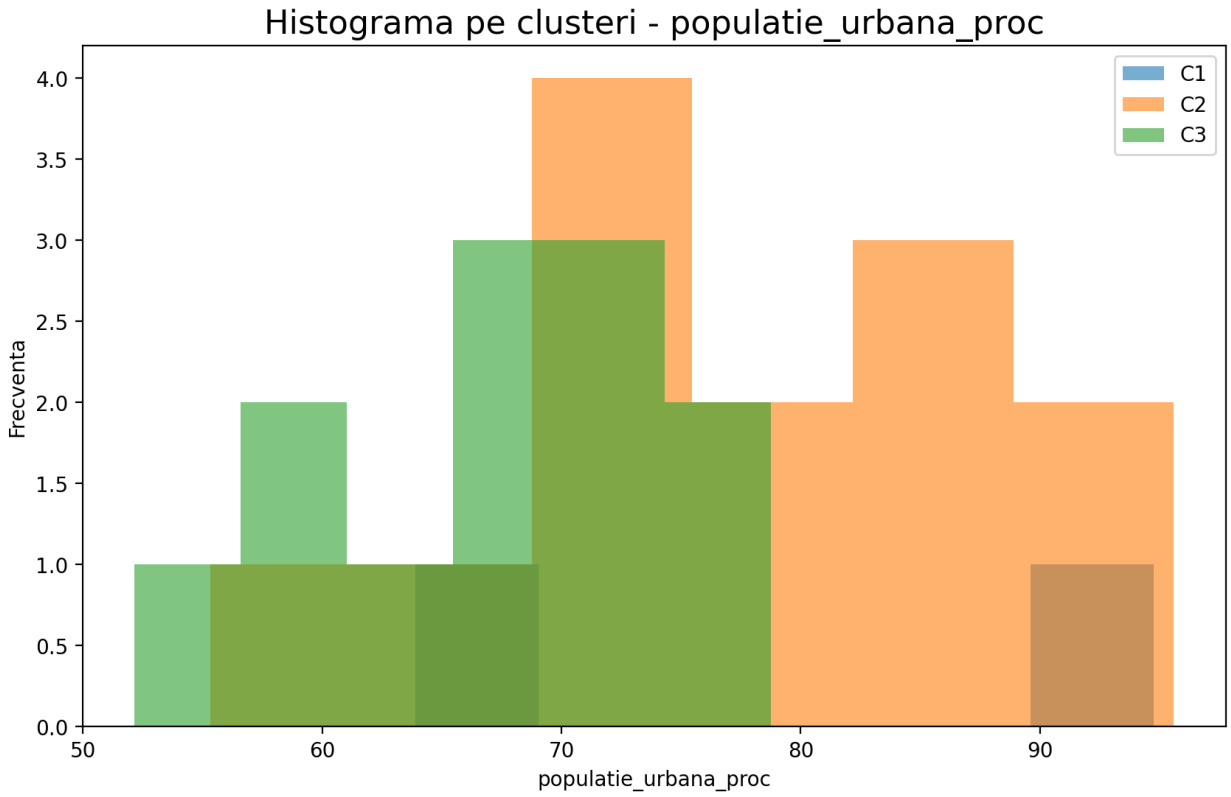
Explicatie:

Comparam nivelul de sanatate / calitatea vietii intre grupuri.



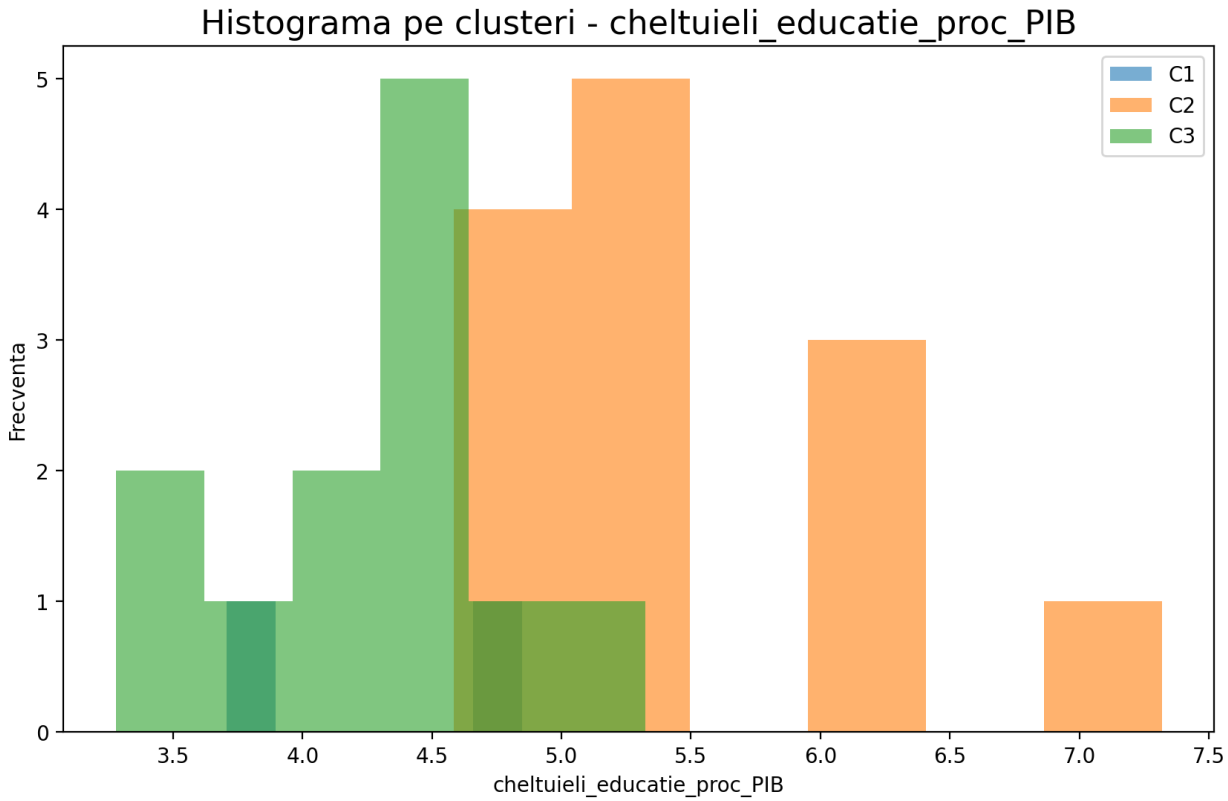
Explicatie:

Vedem diferenta intre tari mai digitalizate si tari mai putin digitalizate.



Explicatie:

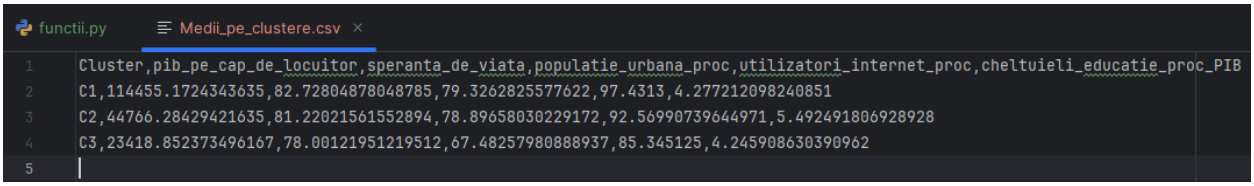
Urbanizarea poate sustine diferente economice si infrastructura.



Explicatie:
Arata daca unele grupuri investesc mai mult/mai putin in educatie.

Medii pe clustere si interpretarea lor

In final, am calculat mediile indicatorilor pe fiecare cluster (un tabel cu medii). Acesta este pasul care ne ajuta sa “dam nume” clusterelor, in functie de profil.



Explicatie:
Din mediile pe clustere se observa, de obicei:

- un cluster cu PIB, internet si speranta de viata mai mari (dezvoltare ridicata)
- un cluster intermediar
- un cluster cu valori mai mici (dezvoltare mai scazuta)

Concluzii

Analiza de clusteri a reusit sa grupeze tarile UE in mod coerent, pe baza indicatorilor socio-economici. Rezultatele sunt usor de interpretat deoarece:

- au fost folosite date reale (World Bank)
- tarile au fost comparate in acelasi an
- datele au fost standardizate
- clusterele au fost evaluate (Silhouette) si explicate (medii + histograme)

In final, proiectul ofera o clasificare a tarilor UE care reflecta diferite niveluri de dezvoltare.